

EFISIENSI EKSPLORASI PADA PERMAINAN MINESWEEPER MENGGUNAKAN METODE CRITIC AS EXPLORER (CAE) DALAM KERANGKA DEEP Q- NETWORK (DQN)

Universitas Indonesia

Dosen Pembimbing

Muhammad Firdaus Syawaludin
Lubis, S.T., M.T., Ph.D.

Dosen Penguji

Yan Maraden, S.T., M.T., M.Sc.
Alfan Prasekal, S.T., M.Sc., Ph.D.


Penulis

Yoel Dwi Miryano
Teknik Komputer (2206059534)

- Pendahuluan
- Tinjauan Pustaka
- Perancangan & Implementasi Sistem
- Eksperimen & Analisis
- Penutup



1. **DQN** sangat bergantung pada strategi eksplorasi
2. **ϵ -greedy** kurang efisien pada *environment* dengan *reward* jarang dan penalti fatal
3. Eksplorasi acak sering menyebabkan terminasi dini
4. *Minesweeper* Adalah **POMDP**
 - **Observasi parsial**
 - **Reward jarang**
 - **Penalti fatal**
5. **CAE** memanfaatkan representasi laten *critic* untuk bonus eksplorasi **UCB**, tanpa menambah **parameter** atau **modul** baru
6. Integrasi **CAE-DQN** belum pernah diuji pada *environment* diskrit berbasis logika dengan penalti terminal





- 1. Validitas Implementasi** (*Correctness*)
- 2. Efisiensi Sampel** (*Performance*)
- 3. Adaptivitas Eksplorasi** (*Mechanism*)
- 4. Kualitas Eksplorasi** (*Behavioral Quality*)

- 1. Memvalidasi Implementasi (*Correctness*)**
- 2. Mengevaluasi Efisiensi Sampel (*Performance*)**
- 3. Menganalisis Adaptivitas Eksplorasi (*Mechanism*)**
- 4. Menilai Kualitas Eksplorasi (*Behavioral Quality*)**

1. Manfaat Praktis


- Implementasi CAE-DQN terverifikasi sebagai acuan riset lanjutan
- Bukti empiris: eksplorasi berbasis ketidakpastian lebih efektif dibandingkan acak pada *environment* risiko tinggi
- Mengurangi ketergantungan pada *tuning* manual eksplorasi

2. Manfaat Akademis

- Evaluasi pertama CAE pada *environment* diskrit-logika dengan penalty terminal
- Analisis kualitatif perilaku *self-annealing* bonus dalam konteks inferensi logis
- Dokumentasi teknik implementasi: *Sherman-Morrison* & normalisasi *Welford*


1. *Minesweeper* 6 x 6, 4 ranjau
2. *One-hot encoding* 6 x 6 x 10
3. **DQN (ϵ -greedy) vs CAE-DQN**
4. Arsitektur dasar identik
5. Pelatihan **80,000** episode
6. Metrik evaluasi
 - **Win rate**
 - **Median progress**
 - **Median reward / episode**
 - **Number of clicks / episode**

1. RL = *agent* belajar mengambil Keputusan melalui interaksi langsung dengan *environment*
2. Tujuan = memaksimalkan *expected discounted return*
3. *Minesweeper*
 - *State* = konfigurasi papan yang teramati (parsial)
 - *Action* = memilih petak untuk dibuka
 - *Reward* = scalar positif/negative (aman, menang, kalah)



$$G_t = \mathbb{E} \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} \right]$$

1. Algoritma *value-based* yang menggabungkan Q-learning dengan *neural network* (NN)
2. Mengaproksimasi $Q^*(s, a)$ melalui NN $Q(s, a; \theta)$
3. Tiga Komponen Utama DQN
 - NN (MLP/CNN)
 - Experience Replay
 - Target Network



Mengapa DQN Sebagai Baseline?

1. Action space diskrit
2. Arsitektur modular
3. Isolasi variabel
4. *Fair Comparison*

Eksplorasi vs Eksploitasi

1. **Eksploitasi:** pilih action dengan estimasi Q tertinggi
2. **Eksplorasi:** pilih action lain untuk memperoleh informasi baru

Mengapa Kurang Efektif di Minesweeper

1. Reward jarang, penalti fatal
2. Eksplorasi acak tidak membedakan petak informatif dan destruktif
3. Fase awal pelatihan cenderung mengalami terminasi dini, sedikit pengalaman berguna



$$a_t = \begin{cases} \text{action acak dari } \mathcal{A}, \text{ dengan probabilitas } \varepsilon \\ \arg \max_{a \in \mathcal{A}} Q(s_t, a; \theta), \text{ dengan probabilitas } 1 - \varepsilon \end{cases}$$

Minesweeper: Tantangan Logika & Observasi Parsial

1. **NP-Complete:** tidak ada algoritma deterministic yang menyelesaikan semua konfigurasi secara efisien

Karakteristik Utama

1. POMDP
2. Reward Jarang + Penalti Fatal



Studi Terdahulu

1. Gardea et al. (2015) – Tabular Q-Learning

- Papan 4 x 4 (3 ranjau) > *win rate* ~70%
- Papan 5 x 5 & 6 x 6 > *win rate* ~<5%
- Gagal karena *state space explosion*

2. Wang & Lei (2025) – DQN (CNN, *policy* = ϵ -greedy)

- Papan 6 x 6 (4 ranjau) > *win rate* ~93.3%
- Dibutuhkan ~1.5 juta *training steps* untuk konvergen
- “There is still room for improvement in sample efficiency”
- Eksplorasi ϵ -greedy masih kurang efektif

“Meskipun DQN berhasil, efisiensi sampel masih dapat ditingkatkan melalui strategi eksplorasi yang lebih efektif”

1. Eksplorasi Berbasis Ketidakpastian

- Konsep yang secara aktif mengarahkan *agent* ke *state* yang kurang dipahami/pasti

2. Upper Confidence Bound (UCB)



- Formula matematis yang memberikan bonus kepada *state* yang jarang dikunjungi
- Berbasis dari teori *Multi-Armed Bandit (MAB)*

3. Critic as Explorer (CAE)

- Memanfaatkan representasi laten $\phi(s)$ dari jaringan *critic* untuk menghitung bonus eksplorasi
- Bonus UCB: $\beta\sqrt{\phi^T A^{-1} \phi}$, dengan A = Gram matrix akumulasi kovarians fitur
- Gram matrix diperbarui dengan *Sherman-Morrison*, normalisasi *running* dengan *Welford*
- Bersifat *self-annealing*

4. Kinerja & Celah

- Terbukti meningkatkan efisiensi sampel di MuJoCo dan MiniHack
- Belum diuji pada *environment* dengan logika diskret dengan penalti terminal seperti *Minesweeper*



MiniHack

Kesenjangan Utama

1. Efisiensi Sampel ϵ -greedy
 - DQN + ϵ -greedy pada 6 x 6 *Minesweeper* mencapai *win rate* 93.3%, namun membutuhkan ~ 1.5 juta *training steps*
 - Efisiensi sampel diakui kurang efisien
2. CAE Belum Teruji di Domain Logika Diskret
 - CAE menawarkan eksplorasi berbasis ketidakpastian laten yang ringan dan *self-annealing*
 - Telah terbukti di MuJoCo/MiniHack, namun belum pernah dievaluasi pada POMDP diskrit dengan penalti fatal seperti *Minesweeper*


Fokus Penelitian

1. Mengintegrasikan CAE dalam DQN pada *Minesweeper* 6 x 6
2. Bukan untuk mengejar *win rate* 93.3%, melainkan untuk mengukur peningkatan relative terhadap strategi ϵ -greedy dengan *training budget* terbatas

Prinsip Kerja

1. Memanfaatkan Kembali lapisan *embedding* jaringan *critic* **DQN**
2. *State* masukan dipetakan menjadi vector fitur $\phi(s)$ oleh lapisan *embedding*
3. $\phi(s)$ digunakan untuk menghitung *exploration bonus* berbasis UCB

$$b(s) = \beta \sqrt{\phi(s)^T A^{-1} \phi(s)}$$
4. Bonus ditambahkan ke *reward*
5. *Agent* belajar untuk memilih *action* yang menuju *state* dengan ketidakpastian tinggi (*novelty*)
6. Semakin sering *state* dikunjungi, bonus mengecil secara otomatis (*self-annealing*)



Formulasi UCB

$$b(s) = \beta \sqrt{\phi(s)^T A^{-1} \phi(s)}$$

1. $\phi(s)$ = vector fitur laten dari *embedding layer*
2. A = *Gram matrix*, akumulasi kovarians *state* yang sudah dikunjungi
3. β = koefisien eksplorasi

Inisialisasi & Pembaruan

1. $A = \lambda I$ (regularisasi *ridge*)
2. Diperbarui secara incremental via Sherman-Morrison setiap kunjungan *state* baru
3. Bonus dinormalisasi Welford (stabilitas numerik)

Integrasi ke Q-value

$$Q^{aug(s,a)} = Q(s, a; \theta) + b(s)$$

Self Annealing

1. Awal: A didominasi λI > bonus besar
2. Seiring akumulasi pengalaman di A , A^{-1} mengecil > bonus menurun otomatis

1. Evaluasi Pertama CAE pada Domain Logika Diskrit

- Integrasi **CAE-DQN** diuji pada *Minesweeper* (POMDP, *reward* jarang, penalti fatal)
- Memperluas pemahaman tentang generalitas eksplorasi berbasis ketidakpastian laten

2. Analisis Kuantitatif


- Metrik utama: *win rate* akhir
- Metrik turunan: AUC, episode menuju 50%, *win rate*, *progress per click*

3. Validasi Empiris *Self-Annealing* pada Terminasi Dini

- Bonus **CAE** menurun alami seiring akumulasi pengalaman dalam *Gram matrix*
- Membuktikan sifat adaptif **CAE** tetap berlaku pada domain dengan reward jarang dan penalti fatal

PERANCANGAN & IMPLEMENTASI SISTEM

Prosedur Pelatihan



1. File


- MinesweeperEnv
- minesweeper_env.py

2. Konfigurasi Papan & Ranjau

- 6 x 6
- 4 ranjau
- *Pseudo-random number generator (seed = 2004)*

3. One-Hot Encoding

- 6 x 6 x 10
- **Kanal 0-8:** petak yang terbuka dengan nilai 0 sampai 8
- **Kanal 9:** petak yang belum terbuka (*unknown*)



1. Struktur Reward

- +36: Menang
- -36: Kalah
- +1: Progress

2. Kondisi Terminal

- **Kalah:** *Agent* memilih petak berisi ranjau
- **Menang:** Seluruh petak yang tidak mengandung ranjau telah berhasil dibuka

3. Kondisi Parsial

- *Agent* tidak memiliki akses langsung terhadap papan asli
- *Agent* hanya melihat representasi *state* dalam bentuk citra *one-hot*
- Lokasi ranjau serta nilai pada petak yang belum terbuka tetap tersembunyi


4. Mekanisme Tambahan

- Keamanan Klik Pertama
- Pembukaan Rekursif Nol

Parameter	Nilai
Ukuran Papan	6 x 6
Jumlah Ranjau	4
Dimensi <i>State</i>	6 x 6 x 10
<i>Action Space</i>	36 Diskrit
<i>Seed Environment</i> (Pelatihan)	2004
<i>Seed Environment</i> (Evaluasi)	1, 2, 3, 4, 5

1. DQN


- 3x Conv2D (32 filter, 3 x 3, ReLU) > Flatten > 2x Dense (128 neuron, ReLU) > Dense (36, linear)
- **Input:** 6 x 6 x 10 (*one-hot encoding*)
- **Output:** Q(s,a) untuk 36 *action*
- **ϵ -greedy**
 - 0.95 > 0.02 (*decay* 0.99995 per langkah pelatihan)
- **Experience Replay**
 - Buffer 300,000 transisi, pelatihan dimulai setelah 10,000 transisi terpenuhi
 - Batch 128 diambil acak > memutus korelasi temporal
- **Target Network**
 - Salinan periodik setiap 1,000 langkah pelatihan > target stabil
- **Pelatihan**
 - Optimizer Adam (*learning rate* = 0.001)
 - Loss MSE
 - Update setiap 4 langkah *environment*



PERANCANGAN & IMPLEMENTASI SISTEM


Ringkasan DQN

Parameter	Nilai/Deskripsi
<i>Arsitektur Jaringan</i>	
Arsitektur CNN	3 lapis konvolusi (32 filter, 3 x 3, ReLU)
Fully Connected	2 lapis (128 neuron, ReLU)
Dimensi Masukan/Keluaran	6 x 6 x 10 / 36 (linear)
<i>Optimasi & Pelatihan</i>	
Optimizer	Adam ($\alpha = 0.001, \epsilon = 10^{-4}$)
Loss Function	MSE
Batch Size / γ	128/0.9
Frekuensi Pelatihan	Setiap 4 langkah interaksi
<i>Experience Replay & Target Network</i>	
Kapasitas Buffer	300,000 (mulai pelatihan pada 10,000)
Target Update	Setiap 1,000 langkah pelatihan
<i>Eksplorasi ϵ-greedy</i>	
ϵ Jadwal	$0.95 > 0.02$ (exponential decay)
Decay Factor	0.99995 / training steps
<i>Konfigurasi Umum</i>	
Total Episode	80,000
Evaluasi Berkala	1,000 episode
Random Seed	2004 (env), 123 (model)



1. CAE-DQN

- CNN identik dengan DQN, namun dengan dua *output*
- $Q(s, a) = 36 \text{ action}$
- $\phi(s) \in \mathbb{R}^{128}$ (vektor fitur laten dari lapisan *embedding*)
- **Bonus Eksplorasi (UCB)**
 - $b(s) = \beta \sqrt{\phi(s)^T A^{-1} \phi(s)}$
 - $A = \lambda I$ ($\lambda = 1.0$), diperbarui secara *online* via *Sherman-Morrison*
 - Bonus dinormalisasi dengan algoritma *Welford*
- **Pemilihan Action**
 - $a = \operatorname{argmax}_a [Q(s, a) + b(s)]$
- **Pelatihan**
 - Bonus ditambahkan ke *reward* sebelum disimpan ke *replay buffer*
 - Target: $y = r + b(s') + \gamma \max_{a'} Q_{\text{target}}(s', a')$




PERANCANGAN & IMPLEMENTASI SISTEM

Ringkasan CAE-DQN

Parameter	Nilai/Deskripsi
<i>Arsitektur Jaringan</i>	
Arsitektur CNN	3 lapis konvolusi (32 filter, 3 x 3, ReLU)
<i>Fully Connected</i>	2 lapis (128 neuron, ReLU)
Dimensi Masukan/Keluaran	6 x 6 x 10 / 36 (linear) + 128 (<i>embedding</i>)
<i>Optimasi & Pelatihan</i>	
Sama dengan konfigurasi DQN (page 24)	
<i>Experience Replay & Target Network</i>	
Sama dengan konfigurasi DQN (page 24)	
<i>Eksplorasi CAE</i>	
Koefisien Eksplorasi β	0.1
Regularisasi <i>Ridge</i> λ	1.0
Pembaruan <i>Gram matrix</i>	<i>Sherman-Morrison</i> (setiap langkah)
Normalisasi Bonus	<i>Welford</i> (running mean & variance)
Rekalkulasi A^{-1} Penuh	Setiap 10,000 langkah
<i>Konfigurasi Umum</i>	
Sama dengan konfigurasi DQN (page 24)	

PERANCANGAN & IMPLEMENTASI SISTEM


CAE-DQN




PELATIHAN		EVALUASI	
Aspek	Keterangan	Aspek	Keterangan
Total Episode	80,000	Model	<i>[algoritma]_best.keras</i> (hasil pelatihan)
Seed Environment	2004	Seed Papan Evaluasi	1, 2, 3, 4, 5
Seed Model	123	Episode per Seed	500
File Logging per Episode	<i>csv/training_[algorithm].csv</i>	Total Episode Evaluasi	2,500 per agent
Metrik	<i>episode, total_reward, progress, win, n_clicks, ϵ/β, learn_rate</i>	Metrik	Greedy murni ($\epsilon = 0$, tanpa bonus CAE)
File Evaluasi Berkala	<i>csv/training_eval_[algorithm].csv</i>	File Hasil Evaluasi	<i>csv/eval_[algoritma]_4mines.csv</i>
Frekuensi Evaluasi	Setiap 1,000 episode	Metrik	<i>Algorithm, board_size, n_mines, eval_seed, episode, win, progress, total_reward, n_clicks</i>
Metrik Evaluasi	<i>median progress, win rate, median reward, waktu</i>		
Penyimpanan Model Terbaik	<i>[algoritma]_best.keras</i> (berdasarkan win rate tertinggi)		
Smoothing Kurva	SMA, window 500 episode		

Kategori	Metode / Metrik
Performa Akhir	<i>Welch's t-test</i> <i>Cohen's d</i>
Interval Kepercayaan	Interval Parametrik <i>Bootstrap</i> (10,000 sampel)
Efisiensi Sampel	AUC (40,000 episode pertama) Episode mencapai 50% <i>win rate</i>
Tren Pelatihan	<i>Mann-Kendall & Sen's Slope</i>
Stabilitas Akhir	Standar Deviasi & Regresi Linier
Kualitas Eksplorasi	<i>Progress per click</i>
Adaptivitas Eksplorasi	Analisis bonus CAE


Total Reward
DQN




Clicks
DQN




CAE-DQN



CAE-DQN



Minesweeper 6x6 with 4 Mines - Training Win Rate vs. Training Time




DQN			
<i>Seed</i>	<i>Average Win Rate</i>	<i>Average Total Reward</i>	<i>Average Number of Clicks</i>
1	59.0%	12.318	6.838
2	59.0%	12.058	6.578
3	56.6%	10.272	6.520
4	58.2%	11.530	6.626
5	57.2%	10.670	6.486
Overall	58.0%	11.370	6.610
CAE-DQN			
<i>Seed</i>	<i>Average Win Rate</i>	<i>Average Total Reward</i>	<i>Average Number of Clicks</i>
1	70.8%	21.140	7.164
2	70.8%	20.708	6.732
3	68.8%	19.580	7.044
4	65.6%	17.176	6.944
5	72.0%	21.760	6.920
Overall	69.6%	20.073	6.961

STATISTIK DESKRIPTIF				EFFECT SIZE		
Group	N	Mean	SD	Metric	Value	Interpretation
DQN	5	58.0%	1.08%	Cohen's d	5.998	Very Large (> 0.8)
CAE-DQN		69.6%	2.51%			
TES NORMALITAS (Shapiro-Wilk)				CONFIDENCE INTERVALS (95%)		
Group	W Statistics	P-value	Normal?	Method	Lower	Upper
DQN	0.8878	0.3460	Yes	Parametric (Welch df)	8.53%	14.67%
CAE-DQN	0.8874	0.3442	Yes	Bootstrap (10k resamples)	9.32%	13.56%
INDEPENDENT T-TEST (Welch's T-Test)				INTERPRETASI		
Test	Value			CAE-DQN secara signifikan mengungguli DQN		
T-Statistic	9.4840					
Degrees of Freedom	5.42					
P-Value	0.000141					
Significant ($\alpha = 0.05$)	Yes					

Perbandingan
Performa Akhir (RQ2)

AREA UNDER CURVE (AUC) {40,000 EPISODES}				INTERPRETASI
Model	AUC	Relatif terhadap DQN		CAE-DQN 2.99x AUC DQN, <i>menunjukkan performa kumulatif (sample efficiency) yang jauh lebih baik sepanjang 40,000 episode pertama</i>
DQN	7835.0	1.00x		
CAE-DQN	23400.0	2.99x		
EPISODE UNTUK MENCAPAI 50% WR				
Model		Episode		
DQN		65,000		
CAE-DQN		6,000		
TREND TEST (Mann-Kendall)				
Model	Trend	P-Value	Slope (sen)	
DQN	Naik	0.0000	0.006530	
CAE-DQN	Turun	0.0000	-0.005942	

Self-Annealing of CAE Bonus During Training



EXPLORATION QUALITY (PROGRESS PER CLICK) 10,000 EPISODE PERTAMA			INTERPRETASI
<i>Model</i>	<i>Mean</i>	<i>Median</i>	<i>Rata-rata progress per click CAE-DQN 12% lebih tinggi daripada DQN pada 10,000 episode awal, menandakan eksplorasi yang lebih terarah dan informatif.</i>
DQN	0.734	0.750	
CAE-DQN	0.823	0.857	
Rasio CAE/DQN (mean)		1.12x	

STD.DEV WR			INTERPRETASI
Model	Std Dev	Interpretasi	CAE-DQN menunjukkan variansi lebih tinggi dan slope negatif yang signifikan terhadap 30,000 episode terakhir pelatihan. Fenomena ini menunjukkan adanya policy collapse saat pelatihan
DQN	0.0297	Lebih Stabil	
CAE-DQN	0.1668	Lebih Tidak Stabil	
REGRESI LINIER CAE-DQN (50-80k EPISODE)			
Metric	Value		
Slope (β_1)	-0.000016		
Intercept (β_0)	1.367540		
P-Value (slope)	0.000000		
R-Squared	0.7785		
Std Error	0.000002		
Significant ($\alpha = 0.05$)	Yes		
MEAN WIN RATE (30,000 EPISODE TERAKHIR)			
Model	Mean Win Rate		
DQN	46.90%		
CAE-DQN	31.55%		

CAE-DQN menunjukkan variansi lebih tinggi dan slope negatif yang signifikan terhadap 30,000 episode terakhir pelatihan. Fenomena ini menunjukkan adanya policy collapse saat pelatihan

Rangkuman Temuan
Kuantitatif

Aspek	Uji / Hasil	p	Efek	Kesimpulan
Performa Akhir	<i>Welch's t-test</i> 69.6% vs 58.0%	< 0.001	$d = 6.00$	Unggul Signifikan
Efisiensi Sampel	AUC 40k Ep. 23,400 vs 7,835	-	2.99x	3x Lebih Cepat
Kecepatan Belajar	Episode $\geq$ 50% WR 6k vs 65k	-	-	10x Lebih Cepat
Tren Pelatihan	<i>Mann-Kendall</i> DQN Naik / CAE-DQN Turun	< 0.001	slope: 0.0065 / -0.0059	DQN Naik CAE-DQN <i>Collapse</i>
Segmen Penurunan	Regresi Linier (50 – 80k) $\beta_1 = -0.000016$	< 0.001	$R^2 = 0.78$	Penurunan Signifikan
Stabilitas Akhir	Std. Dev WR 0.0297 vs 0.1668	-	-	DQN Lebih Stabil
Adaptivitas Eksplorasi	Bonus CAE 10 > 0.5 (20k ep.)	-	-	<i>Self-Annealing</i>
Kualitas Eksplorasi	Progress/Klik 0.823 vs 0.734	-	1.12x	12% Lebih Informatif

1. Performa & Efisiensi Sampel (RQ2)

- CAE-DQN mencapai *win rate* **69.6%** vs DQN **58.0%**
- Belajar jauh lebih cepat dan efisien

2. *Self-Annealing* (RQ3)

- Bonus eksplorasi menurun alami seiring akumulasi pengalaman di *Gram matrix*

3. Kualitas Eksplorasi (RQ4)

- *Progress per click* CAE-DQN 12.1% lebih tinggi
- *Agent* cenderung memilih petak yang informatif > mempercepat pemecahan CSP *Minesweeper*
- Menghindari tebakan acak, menjaga episode lebih panjang

4. *Policy Collapse & Recovery* (Tambahan)

- Bonus yang menyusut tajam menyebabkan *agent* terjebak di *local minimum*
- Bonus residual (~0.5) masih mampu mendiversifikasi data di *replay buffer*

1. Validitas Implementasi

- CAE-DQN merealisasikan eksplorasi berbasis ketidakpastian sesuai formulasi CAE

2. Efisiensi Sampel & Performa

- *Win rate*: **69.6%** vs **58.0%** ($p < 0.001$, $d = 6.00$)
- *50% win rate*: 6,000 vs 65,000 episode (10x lebih cepat)
- *AUC 40K*: 23,400 vs 7,835 (2.99x)

3. Self-Annealing Bonus

- Bonus menurun alami dari $\sim 10 > 0.5$ dalam 20k episode tanpa adanya penjadwalan manual

4. Kualitas Eksplorasi

- *Progress per click* **12.1%** lebih informatif

5. Policy Collapse & Recovery

- Bonus yang menyusut menyebabkan *greedy* terjebak pada *local minimum*
- Bonus residual mendorong pemulihan parsial

***CAE strategi yang efektif untuk POMDP
dengan reward jarang dan penalti
fatal***

1. Papan Lebih Kompleks

- Uji CAE-DQN pada 9×9 (10 ranjau) atau 16×16 (40 ranjau) untuk menguji skalabilitas.

2. CAE+ untuk *Reward* Sangat Jarang

- Tambahkan jaringan *Inverse Dynamics* untuk mempercepat pembelajaran representasi laten pada *environment* yang lebih sulit.

3. Domain Logika Diskret Lainnya

- Terapkan CAE-DQN pada *Battleship*, *Mastermind*, atau nonogram untuk menguji generalitas temuan.

4. Studi Ablasi Normalisasi Welford

- Evaluasi dampak normalisasi *Welford* terhadap stabilitas pelatihan CAE pada *Minesweeper*.



***THANK
YOU!***

[1] Y. Li et al., “CAE: Repurposing the critic as an explorer in deep reinforcement learning,” arXiv preprint arXiv:2503.18980, 2025, also presented at relevant conference.

[2] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski et al., “Human-level control through deep reinforcement learning,” *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.

[9] W. Wang and C. Lei, “Training a minesweeper agent with deep q-network and supervised learning,” *Applied Sciences*, vol. 15, no. 3, p. 745, 2025.

[7] R. S. Sutton and A. G. Barto, *Reinforcement learning: An introduction*, 2nd ed. MIT press, 2018.