

Efisiensi Eksplorasi pada Permainan Minesweeper menggunakan Metode Critic as Explorer (CAE) dalam Kerangka Deep Q-Network (DQN)

Yoel Dwi Miryano¹ and Muhammad Firdaus Syawaludin Lubis, S.T., M.T., Ph.D.²

Dept. of Electrical Engineering
Universitas Indonesia
Depok, Indonesia
yoel.dwi@ui.ac.id, chemfirus@gmail.com

Abstract—Strategi eksplorasi ε -greedy pada Deep Q-Network (DQN) sering tidak efisien pada *environment* dengan observasi parsial, *sparse reward*, dan penalti terminal fatal seperti Minesweeper. Penelitian ini mengintegrasikan Critic as Explorer (CAE) ke dalam DQN untuk mengarahkan eksplorasi berdasarkan ketidakpastian laten jaringan *critic*, bukan aksi acak semata. Eksperimen dilakukan pada Minesweeper 6×6 dengan 4 ranjau selama 80,000 episode, menggunakan arsitektur CNN yang sama untuk DQN dan CAE-DQN. Evaluasi pada lima *seed* papan menunjukkan CAE-DQN mencapai *win rate* 69.6%, lebih tinggi dari DQN sebesar 58.0% ($p < 0.001$, $d = 6.00$), serta mencapai *ambang win rate* 50% jauh lebih cepat (6,000 vs. 65,000 episode). Analisis tambahan menunjukkan bahwa *random picker* hanya mencapai 2.8%, sedangkan *rule-based deterministic agent* mencapai 74.3% namun masih memiliki *forced guess rate* 43.7%. Temuan ini menegaskan bahwa Minesweeper memuat rezim deduktif sekaligus probabilistik, dan CAE meningkatkan efisiensi eksplorasi RL tanpa menambah parameter jaringan.

Index Terms—Reinforcement Learning, Deep Q-Network, Exploration, Critic as Explorer, Minesweeper, Sample Efficiency.

I. PENDAHULUAN

Reinforcement Learning (RL), khususnya DQN, telah berhasil menyelesaikan berbagai tugas pengambilan keputusan kompleks [1], [2]. Namun, performa DQN sangat dipengaruhi oleh kualitas eksplorasi. Pada *environment* dengan observasi parsial (Partially Observable Markov Decision Process/POMDP), *sparse reward*, dan penalti terminal fatal, aksi acak yang dihasilkan ε -greedy dapat mengakhiri episode sebelum *agent* memperoleh pengalaman yang informatif.

Minesweeper merupakan contoh yang sesuai untuk menguji masalah tersebut. Permainan ini tergolong NP-complete [3], menuntut inferensi dari angka yang terbuka, dan menghukum satu keputusan salah dengan kekalahan langsung. Pada fase awal pelatihan, DQN standar cenderung mengklik petak secara acak sehingga pengalaman yang masuk ke *replay buffer* pendek dan kurang beragam. Wang dan Lei (2025) menunjukkan bahwa DQN berbasis CNN dapat mencapai *win rate* tinggi pada papan 6×6 , tetapi masih membutuhkan sekitar 1.5 juta *training steps*, sehingga efisiensi sampel tetap menjadi celah penelitian [4].

Penelitian ini mengusulkan CAE-DQN, yaitu integrasi CAE [5] ke dalam DQN. CAE memanfaatkan representasi laten dari jaringan *critic* untuk menghitung bonus eksplorasi berbasis Upper Confidence Bound (UCB). Kontribusi utama penelitian ini adalah: (1) mengimplementasikan CAE-DQN pada Minesweeper 6×6 dengan representasi *one-hot* spasial; (2) membandingkan CAE-DQN terhadap DQN, *random picker*, dan *rule-based deterministic agent*; (3) menjelaskan perbedaan kasus *reasoning* dan probabilistik pada Minesweeper; serta (4) menganalisis *self-annealing*, kompleksitas, dan fenomena *policy collapse* pada CAE-DQN.

II. TINJAUAN PUSTAKA

A. DQN dan Masalah Eksplorasi

DQN mengaproksimasi fungsi nilai aksi optimal $Q^*(s, a)$ menggunakan jaringan saraf berparameter θ [1]. Stabilitas pembelajaran ditopang oleh *experience replay*, *target network*, dan optimasi Mean Squared Error terhadap target temporal-difference. Pada implementasi standar, DQN memilih aksi melalui ε -greedy: aksi acak dipilih dengan probabilitas ε , sedangkan aksi dengan Q tertinggi dipilih dengan probabilitas $1 - \varepsilon$.

Kelemahan strategi ini muncul ketika aksi acak bersifat destruktif. Pada Minesweeper, satu klik pada ranjau langsung mengakhiri episode. Karena *reward* positif baru terkumpul setelah rangkaian klik aman, eksplorasi acak tidak hanya boros sampel, tetapi juga membatasi kesempatan *agent* mengamati konfigurasi papan yang lebih dalam.

B. Deterministik, Probabilistik, dan POMDP

Minesweeper memiliki dua rezim keputusan. Pada sebagian *state*, aturan lokal mampu membuktikan bahwa petak tertentu aman atau berisi ranjau. Contohnya, jika angka 1 hanya memiliki satu tetangga tertutup, tetangga tersebut pasti ranjau; jika jumlah ranjau di sekitar angka telah terpenuhi, tetangga tertutup lain dapat dibuka dengan aman. Kondisi seperti ini merupakan kasus deterministik atau *reasoning*.

Namun, tidak semua konfigurasi dapat diselesaikan oleh aturan lokal. Ketika beberapa konfigurasi tersembunyi sama-sama konsisten dengan angka yang terlihat, tidak ada petak




Fig. 1. Arsitektur konseptual CAE yang menggunakan representasi laten jaringan *critic* sebagai sumber bonus eksplorasi [5].

yang dapat dibuktikan aman; keputusan berubah menjadi tebakan berbasis risiko atau probabilitas. Karena itu, penggunaan RL pada penelitian ini bukan dimaksudkan untuk menggantikan *solver* deterministik terbaik, melainkan untuk menguji bagaimana *agent* belajar memilih aksi dari pengalaman ketika deduksi pasti tidak selalu tersedia.

Secara formal, dinamika internal *Minesweeper* memenuhi sifat Markov jika *state* didefinisikan sebagai kondisi lengkap papan: posisi ranjau, angka tiap petak, status petak terbuka, jumlah klik, dan kondisi terminasi. Transisi setelah aksi a_t hanya bergantung pada *state* lengkap saat ini. Akan tetapi, *agent* tidak mengamati *state* lengkap tersebut; ia hanya menerima observasi berupa petak terbuka dan petak *unknown*. Oleh karena itu, dari sudut pandang *agent*, masalah ini adalah POMDP [6], [7].

C. Critic as Explorer

Istilah *critic* pada CAE merujuk pada jaringan yang menilai kualitas aksi. Dalam DQN, jaringan $Q(s, a; \theta)$ berperan sebagai *critic* karena menghasilkan estimasi nilai untuk setiap aksi. CAE menggunakan kembali jaringan ini sebagai pengarah eksplorasi: lapisan *embedding* sebelum keluaran Q menghasilkan fitur laten $\phi(s)$, lalu fitur tersebut digunakan untuk menilai apakah *state* serupa sudah sering dikunjungi.

Bonus eksplorasi CAE dihitung dengan formulasi UCB:

$$b(s) = \beta \sqrt{\phi(s)^\top \mathbf{A}^{-1} \phi(s)}, \quad (1)$$

di mana β adalah koefisien eksplorasi dan $\mathbf{A}$ adalah *Gram matrix* yang mengakumulasi kovarians fitur laten [5]. Ketika fitur serupa jarang muncul, nilai bonus tinggi dan *agent* terdorong mengeksplorasi. Seiring pengalaman bertambah, $\mathbf{A}^{-1}$ mengecil sehingga bonus turun secara alami. Sifat *self-annealing*

ini membuat CAE dapat bertransisi dari eksplorasi menuju eksploitasi tanpa jadwal *decay* manual seperti ε -greedy.

III. METODOLOGI

A. Environment dan Representasi State

Environment menggunakan papan 6×6 dengan 4 ranjau. Setiap episode berakhir ketika *agent* membuka ranjau atau berhasil membuka seluruh petak aman. Untuk mencerminkan permainan standar dan menghindari terminasi instan, klik pertama dibuat aman dengan memindahkan ranjau apabila petak pertama yang dipilih berisi ranjau. Petak bernilai 0 dibuka secara rekursif bersama tetangganya.

Observasi *agent* direpresentasikan sebagai tensor $6 \times 6 \times 10$. Kanal 0 sampai 8 merepresentasikan angka petak yang telah terbuka, sedangkan kanal 9 merepresentasikan petak yang masih tertutup. Tidak ada kanal khusus untuk ranjau, sehingga lokasi ranjau tetap tersembunyi sampai episode berakhir. Struktur *reward* adalah $+36$ untuk menang, -36 untuk kalah, dan $+1$ untuk setiap aksi yang membuka minimal satu petak aman baru.

B. DQN dan CAE-DQN

DQN dan CAE-DQN menggunakan arsitektur CNN yang identik: tiga lapis konvolusi dengan 32 *filter* 3×3 , dua lapis *fully connected* berukuran 128, dan keluaran linear 36 neuron untuk nilai Q tiap petak. Aksi pada petak yang telah terbuka di-*masking* agar tidak dipilih. Pelatihan menggunakan Adam ($\alpha = 0.001$), *batch size* 128, $\gamma = 0.9$, *replay buffer* 300,000 transisi, mulai belajar setelah 10,000 transisi, pembaruan jaringan setiap 4 langkah interaksi, dan pembaruan *target network* setiap 1,000 langkah pelatihan.

DQN menggunakan ε -greedy dengan ε dari 0.95 menuju 0.02 melalui *exponential decay* 0.99995. CAE-DQN tidak menggunakan eksplorasi acak tersebut. CAE-DQN mengambil fitur laten $\phi(s) \in \mathbb{R}^{128}$ dari lapisan *embedding*, menghitung bonus pada Persamaan 1 dengan $\beta = 0.1$ dan $\lambda = 1.0$, memperbarui *Gram matrix* melalui *Sherman–Morrison*, serta menormalkan bonus dengan algoritma Welford. Bonus ditambahkan pada nilai aksi saat pemilihan aksi dan pada *reward* ekstrinsik sebelum transisi disimpan.

C. Protokol Evaluasi

Kedua *agent* dilatih selama 80,000 episode dengan *seed environment* 2004 dan *seed model* 123. Evaluasi berkala dilakukan setiap 1,000 episode menggunakan *policy greedy* murni, dan *checkpoint* terbaik disimpan berdasarkan *win rate*. Evaluasi akhir dilakukan pada lima *seed* papan berbeda (1–5), masing-masing 500 episode. Pada evaluasi akhir, DQN dan CAE-DQN tidak melakukan pembelajaran; CAE-DQN juga tidak menerima bonus eksplorasi, sehingga hasil mencerminkan kualitas *policy* yang telah dipelajari.

Sebagai pembanding tambahan, digunakan *random picker* dan *rule-based deterministic agent*. *Random picker* memilih petak tertutup secara uniform. *Rule-based deterministic agent* menerapkan aturan lokal *Minesweeper*; jika tidak ada petak aman yang dapat dibuktikan, ia melakukan *forced guess*.




Fig. 2. Kurva *win rate* terhadap waktu pelatihan DQN dan CAE-DQN selama 80,000 episode.

TABLE I

RANGKUMAN EVALUASI EMPAT ALGORITMA PADA 5 seed, 500 EPISODE PER seed.

Algoritma	Win	Reward	Klik	FG
Random picker	2.8%	-30.692	4.263	100.0%
Rule-based deterministic	74.3%	23.842	7.360	43.7%
DQN	58.0%	11.370	6.610	-
CAE-DQN	69.6%	20.073	6.961	-

Kolom *forced guess* hanya berlaku untuk pembandingan non-RL karena DQN dan CAE-DQN tidak menggunakan aturan simbolik eksplisit untuk menandai tebakan.

IV. HASIL DAN ANALISIS

A. Performa dan Efisiensi Sampel

Gambar 2 menunjukkan bahwa CAE-DQN belajar jauh lebih cepat daripada DQN. CAE-DQN mencapai *win rate* puncak sekitar 71% dalam 28.8 menit dan menembus ambang 50% pada episode ke-6,000. Sebaliknya, DQN baru mencapai ambang 50% pada episode ke-65,000 dan mencapai puncak sekitar 55% setelah 204.4 menit. Pada 40,000 episode pertama, AUC CAE-DQN adalah 23,400, sedangkan DQN hanya 7,835, atau sekitar 2.99 kali lebih kecil.

Tabel I merangkum evaluasi akhir. CAE-DQN mencapai *win rate* 69.6%, lebih tinggi dari DQN 58.0%. Uji normalitas Shapiro-Wilk tidak menolak normalitas untuk DQN ($W = 0.888$, $p = 0.346$) maupun CAE-DQN ($W = 0.887$, $p = 0.344$). Uji Welch menunjukkan perbedaan signifikan, $t(5.42) = 9.48$, $p < 0.001$, dengan *Cohen's d* = 6.00. Interval kepercayaan 95% untuk selisih *win rate* adalah [8.53%, 14.67%], dan *bootstrap* 10,000 sampel menghasilkan interval serupa [9.32%, 13.56%].

Hasil pembandingan memperjelas posisi penelitian. *Random picker* hanya mencapai 2.8%, sehingga performa DQN dan CAE-DQN tidak dapat dijelaskan oleh keberuntungan. *Rule-based deterministic agent* mencapai 74.3%, lebih tinggi dari kedua *agent* RL, yang menunjukkan kuatnya aturan simbolik pada papan kecil. Namun, *forced guess rate* 43.7% menunjukkan bahwa hampir setengah episode tetap memasuki kondisi ambigu. Dengan demikian, *Minesweeper* tidak sepenuhnya deterministik dari sudut observasi *agent*; terdapat situasi di mana keputusan harus berbasis risiko.




Fig. 3. *Self-annealing* bonus eksplorasi CAE selama 20,000 episode pelatihan.

TABLE II

ANALISIS KOMPLEKSITAS DQN DAN CAE-DQN.

Model	Param.	MAC/state	Mem. CAE
DQN	190,148	935,680	0 MiB
CAE-DQN	190,148	935,680	0.25 MiB

B. Self-Annealing dan Kualitas Eksplorasi

Gambar 3 menunjukkan bonus CAE menurun dari sekitar 10 menjadi sekitar 2 dalam 1,000 episode pertama, lalu turun bertahap ke sekitar 0.5 pada episode ke-20,000. Penurunan ini sesuai mekanisme internal CAE: setiap fitur laten yang dikunjungi menambah informasi pada *Gram matrix*, sehingga $\mathbf{A}^{-1}$ mengecil dan bonus pada *state* serupa berkurang. Lonjakan kecil di sekitar episode 3,000 mengindikasikan pertemuan dengan konfigurasi yang relatif baru.

Kualitas eksplorasi juga diukur melalui *progress per click*, yaitu proporsi klik yang membuka informasi baru pada 10,000 episode awal. CAE-DQN memperoleh rata-rata 0.823, sedangkan DQN memperoleh 0.734. Peningkatan relatif 12.1% ini menunjukkan bahwa eksplorasi CAE lebih terarah: bonus ketidakpastian mendorong *agent* memilih petak yang lebih informatif dibanding aksi acak ϵ -greedy.

C. Kompleksitas

Tabel II menunjukkan bahwa peningkatan performa CAE-DQN tidak berasal dari penambahan kapasitas jaringan. DQN dan CAE-DQN sama-sama memiliki 190,148 parameter dan 935,680 operasi MAC per *state*. CAE hanya menambahkan operasi eksplorasi pada ruang laten berdimensi 128, sekitar 32,768 operasi per langkah, serta dua matriks 128×128 untuk $\mathbf{A}$ dan $\mathbf{A}^{-1}$ dengan memori sekitar 0.25 MiB. Biaya ini kecil dibanding estimasi mentah *replay buffer* ~ 826.55 MiB untuk 300,000 transisi.

D. Reasoning, Probabilitas, dan Policy Collapse

Untuk menjawab apakah *agent* hanya mengikuti probabilitas atau dapat menunjukkan perilaku yang menyerupai penalaran, dilakukan studi kasus pada dua jenis *state*. Pada kasus *reasoning*, terdapat petak yang dapat dibuktikan aman melalui *constraint* lokal; DQN memilih (4,3) dan CAE-DQN memilih (3,2), keduanya memiliki probabilitas ranjau 0.0. Pada kasus probabilistik, tidak ada petak yang dapat dibuktikan aman; DQN memilih (1,5) dan CAE-DQN memilih (2,5), keduanya




Fig. 4. Kiri: kasus *reasoning*, terdapat petak aman yang dapat dibuktikan. Kanan: kasus probabilistik, tidak terdapat petak yang pasti aman sehingga aksi dipilih berdasarkan risiko.

memiliki estimasi risiko 0.09375, salah satu nilai terendah pada konfigurasi tersebut.

Temuan tersebut menunjukkan bahwa perilaku *agent* dapat dibaca sebagai *reasoning-like behavior* ketika kebijakan selaras dengan deduksi lokal, tetapi berubah menjadi pemilihan berbasis risiko ketika informasi tidak cukup. Dalam konteks ini, RL relevan karena *agent* belajar mengurutkan aksi berdasarkan estimasi *return* jangka panjang di bawah ketidakpastian.

Meskipun CAE-DQN sangat efisien pada fase awal, kurva pelatihan menunjukkan penurunan setelah episode 50,000–60,000. Analisis pada 30,000 episode terakhir menunjukkan standar deviasi *win rate* CAE-DQN 0.1668, jauh lebih tinggi dari DQN 0.0297; regresi linier pada rentang episode 50,000–80,000 menghasilkan kemiringan negatif signifikan ($\beta_1 = -0.000016$, $p < 0.001$, $R^2 = 0.7785$). Fenomena ini disebut *policy collapse*: *policy* yang awalnya kuat kehilangan keberagaman aksi dan terkunci pada pola keputusan sempit.

Penjelasan utamanya adalah dinamika *replay buffer*. Dengan kapasitas 300,000 transisi dan panjang lintasan sekitar 6–7 langkah, *buffer* mulai jenuh pada kisaran episode 45,000–50,000. Transisi awal yang kaya eksplorasi dan memiliki bonus CAE tinggi mulai tergeser oleh transisi yang lebih homogen dari fase *self-annealing*. Ketika distribusi pengalaman menjadi sempit, jaringan rentan terhadap *catastrophic forgetting*. DQN lebih stabil karena $\epsilon_{\min} = 0.02$ tetap menyuntikkan pengalaman acak, sedangkan CAE-DQN pada fase lanjut lebih sering mengikuti *greedy policy*. Namun, model yang digunakan pada evaluasi akhir adalah *checkpoint* terbaik sebelum *collapse*, sehingga tetap mencapai generalisasi 69.6% pada lima *seed* evaluasi.

V. KESIMPULAN

CAE-DQN berhasil meningkatkan efisiensi eksplorasi DQN pada *Minesweeper* 6×6 dengan 4 ranjau. Dibanding DQN standar, CAE-DQN memperoleh *win rate* lebih tinggi (69.6% vs. 58.0%), mencapai ambang 50% jauh lebih cepat (6,000 vs. 65,000 episode), dan menghasilkan eksplorasi awal yang lebih informatif melalui peningkatan *progress per click* 12.1%.

Analisis tambahan menunjukkan bahwa permainan ini tidak dapat direduksi menjadi sekadar aturan deterministik atau peluang acak. *Random picker* gagal hampir seluruhnya (2.8%),

sementara *rule-based deterministic agent* kuat (74.3%) tetapi masih membutuhkan *forced guess* pada 43.7% episode. Dengan demikian, *Minesweeper* memuat kasus *reasoning* dan probabilistik; RL relevan untuk mempelajari kebijakan ketika observasi parsial tidak memberi bukti deterministik yang cukup.

CAE juga terbukti ringan secara arsitektural: tidak menambah parameter jaringan dan hanya menambahkan memori matriks sekitar 0.25 MiB. Keterbatasan utama adalah risiko *policy collapse* setelah bonus mengecil dan *replay buffer* menjadi homogen. Penelitian selanjutnya dapat menguji papan lebih besar, mekanisme *replay* yang menjaga keragaman pengalaman, CAE+ untuk *reward* yang lebih jarang, serta studi ablasi terhadap normalisasi Welford dan batas minimum bonus eksplorasi.

REFERENCES

- [1] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski *et al.*, “Human-level control through deep reinforcement learning,” *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.
- [2] R. S. Sutton and A. G. Barto, *Reinforcement learning: An introduction*, 2nd ed. MIT press, 2018.
- [3] R. Kaye, “Minesweeper is NP-complete,” *The Mathematical Intelligencer*, vol. 22, no. 2, pp. 9–15, 2000.
- [4] W. Wang and C. Lei, “Training a minesweeper agent with deep q-network and supervised learning,” *Applied Sciences*, vol. 15, no. 3, p. 745, 2025.
- [5] Y. Li *et al.*, “CAE: Repurposing the critic as an explorer in deep reinforcement learning,” *arXiv preprint arXiv:2503.18980*, 2025, also presented at relevant conference.
- [6] L. P. Kaelbling, M. L. Littman, and A. R. Cassandra, “Planning and acting in partially observable stochastic domains,” *Artificial intelligence*, vol. 101, no. 1-2, pp. 99–134, 1998.
- [7] M. T. Spaan, “Partially observable Markov decision processes,” in *Reinforcement Learning: State-of-the-Art*. Springer, 2012, pp. 387–414.